

# LDA 妯 嶲鎖他堪 >

鑿爍焜鎡 <88>

## 数据获取

网站传送门 转载了各大微信公众号的历史文章。我们从该网站上随机抽取三个关注人数较多的娱乐八卦公众号，抓取 2016 年 4 月中旬至 2017 年 2 月中旬的所有历史文章，及其阅读数与点赞数等信息，共计 1953 条记录作为我们的语料库。

## 理论

### LDA 模型

潜在狄利克雷分布 (Latent Dirichlet allocation, LDA) 主题模型，是文本挖掘中著名的生成概率模型。它由 David M. Blei、Andrew Y. Ng、Michael I. Jordan 在 2013 年提出。

记号：

1. 一个词语是该离散数据中最基本的单位，词典中所有词语由  $1, 2, \dots, V$  索引。每个词语可由一个单位基向量表示，即词典中的第  $v$  个词表示为  $V$  维向量  $w$ ，其中  $w^v = 1$   $w^u = 0, u \neq v$ ；
2. 一篇具有  $N$  个词的文档记为词序列  $\vec{w}_n = (w_1, w_2, \dots, w_N)$ ，其中  $w_n$  是序列中的第  $n$  个词语；
3.  $M$  篇文档组成的语料库记为  $D = \{\vec{w}_1, \vec{w}_2, \dots, \vec{w}_M\}$ 。

### DGP:

LDA 是一个层次贝叶斯模型，它的基本思想是：一篇文章可能具有多个主题，而文档的主题分布服从一个潜在的狄利克雷分布，而每一个主题代表一种词语分布，即一篇文档的生成服从以下步骤：

1. 选择  $N \sim Poisson(\xi)$ ；
2. 选择  $\theta \sim Dir(\alpha)$ ；
3. 对于  $N$  个词中的每一个词语  $w_n$ ：
  - 选择其来自于哪一个主题  $z_n \sim Multinomial(\theta)$ ；
  - 从多项式条件分布  $p(w_n|z_n, \beta)$  中生成一个词语  $w_n$ 。

其中假设主题数  $k$  (狄利克雷分布的维度) 是已知且固定的；给定主题，词语的条件分布  $k \times V$  维矩阵  $\beta$  where  $\beta_{ij} = p(w^j = 1 | z^i = 1)$  是未知非随机矩阵。文档长度  $N$  服从泊松分布，且与过程 1、2. 独立。

结构可表述如下图???




Figure 1: LDA 结构图

需注意与简单狄利克雷-多项式分布聚类模型不同，LDA 模型允许一个文档具有多个主题。

具有图 [LDA 结构图] 所示结构的模型在贝叶斯方法中被称为层次模型（Gelman et al., 1995），或条件独立层次模型（conditionally independent hierarchical model, Kass and Steffey, 1989）。LDA 参数  $\alpha, \beta$  可以由经验贝叶斯方法进行估计。

## 推断与参数估计

LDA 模型最终的目的是，给定文档，推断其潜在主题的后验分布：

$$p(\theta, \vec{z} | \vec{w}, \alpha, \beta) = \frac{p(\theta, \vec{z}, \vec{w} | \alpha, \beta)}{p(\vec{w} | \alpha, \beta)}$$

具体过程可以采用拉普拉斯逼近、变分近似法、MCMC 方法计算。本文中我们采用 MCMC 方法，利用 gibbs 抽样近似计算后验分布。